

1

Supervised Transfer

(alvo rotulado)

Fonte (S)	✔ rótulos
Alvo (T)	✔ dados ✔ rótulos (muitos)

Desvio real, mas o alvo é totalmente rotulado

Fonte (S)
rotulada

Alvo (T)
rotulado

fronteira da fonte
(já não serve)

fronteira re-treinada

desvio

Ambos os domínios têm rótulos: a fronteira do alvo pode ser reestimada diretamente. Não é, a rigor, um problema de shift — é só re-treino.

Fine-tuning: tudo pode se mover

x_T

Encoder
 h_ψ

adapta

Cabeça
 g_ϕ

adapta

$\hat{y}$

Modelo pré-treinado
(fonte)

fine-tuning

Modelo no alvo

Requisito: rótulos do alvo em volume — justamente o gargalo que motiva 2–5.

2

SSDA

(poucos rótulos do alvo)

Fonte (S)	✔ rótulos
Alvo (T)	✔ dados ✔ rótulos (poucos, K)

Alvo quase todo sem rótulo — só K âncoras

Fonte (S)
rotulada

Alvo (T)
K rótulos

K âncoras rotuladas

fronteira recalibrada

desvio

Poucos rótulos bastam para reposicionar a percepção, não para reaprender o vocabulário de classes: adapta-se o encoder, congela-se a cabeça.

Congelar a cabeça, adaptar o encoder

1) Pré-treino na fonte (rótulos abundantes)

x_S

Encoder
 h_ψ

treina

Cabeça
 g_ϕ

treina

$\hat{y}$

2) Adaptação no alvo (K rótulos)

x_T

Encoder
 h_ψ

adapta

Cabeça
 g_ϕ

congelada

$\hat{y}$

Recalibrar o ouvido, não reescrever o dicionário: muda-se a percepção, preserva-se a semântica.

3

UDA

(alvo sem rótulos)

Fonte (S)	✔ rótulos
Alvo (T)	✔ dados ✗ rótulos

Alvo observável, porém sem qualquer rótulo

Fonte (S)
rotulada

Alvo (T)
classes desconhecidas

sem rótulo: nenhuma forma, só pontos

a fronteira do alvo é inobservável

desvio

Vê-se onde os dados do alvo estão, nunca o que são. Só resta alinhar as duas distribuições no espaço latente e herdar a cabeça treinada na fonte.

Alinhar os domínios no espaço latente

x_S

Encoder
 h_ψ

adapta

Cabeça
 g_ϕ

perda de classe

Discriminador de domínio

S ou T?

gradiente revertido: o encoder aprende a enganar o discriminador

Resultado: espaço latente alinhado

fonte e alvo estatisticamente indistinguíveis

4

DG

(sem dados do alvo)

Fonte (S)	✔ rótulos
Alvo (T)	✗ dados ✗ rótulos

O alvo sequer é observado no treino

Múltiplas variações simuladas da fonte
(augmentação + domain randomization)

Alvo real: fora do treino, e desconhecido

A aposta: se o suporte das simulações for largo o bastante, o alvo real cai dentro dele.
Hipótese forte — e não verificável sem amostra.

Robustez construída antes de ver o alvo

x_{sim}

Encoder
 h_ψ

treina

Cabeça
 g_ϕ

treina

$\hat{y}$

Representação latente invariante

fronteira estável sob qualquer variação coberta pelo suporte simulado

5

CL

(sem rótulos, fonte ou alvo)

Fonte (S)	✗ rótulos
Alvo (T)	✔ dados (talvez) ✗ rótulos

Nenhum rótulo: o sinal vem da própria amostra

Vistas / augmentações da mesma amostra

Amostra
 x_i

original

geometria

ruído/cor

Duas vistas da mesma amostra devem colapsar; amostras distintas devem se repelir. A tarefa pretexto substitui o par (x, y) por completo.

Aproximar vistas, afastar amostras distintas

Encoder
 h_ψ

sem rótulos

pares positivos (mesma amostra) se atraem

pares negativos (amostras distintas) se repelem

Na prática: CL não substitui os regimes 1-4

É pré-treino. Um encoder contrastivo dá o ponto de partida sobre o qual SSDA ou UDA são aplicados.

○ classe A (rotulada)

△ classe B (rotulada)

○ amostra sem rótulo (classe desconhecida)

● âncora rotulada do alvo (K)

— fronteira estimada na fonte

- - - fronteira transferida (desajustada)

🔒 parâmetros congelados

🔓 parâmetros treináveis